

## AI 프로젝트 및 배포 위험: 표현 및 합법화

수체타 라히리  
시러큐스 대학교  
[sulahir@sy.edu](mailto:sulahir@sy.edu)

제프리 살츠  
시러큐스 대학교  
[jsaltz@sy.edu](mailto:jsaltz@sy.edu)

### 추상적인

이 연구는 실무자들이 AI 프로젝트 관련 위험을 식별하고 관리하여 AI 프로젝트 실패를 줄이는 방법을 살펴봅니다. 구체적으로, 16명의 데이터 과학 실무자를 대상으로 한 정성적 연구를 통해 이 연구는 실무자들이 AI 프로젝트 실패 위험을 어떻게 표현하고 완화하는지에 대한 통찰력을 제공합니다. 이 연구의 주제별 분석에서 6가지 핵심 주제(윤리적 위험, BlackBox 모델, 데이터 프라이버시, 데이터 저장, 재무적 위험 및 성공 기준)가 확인되었습니다. 추가 분석에서는 이러한 위험을 식별하고 완화하는 요인을 탐구했습니다. 구체적으로, 대행사(소비자 및 기관 주도)와 Bourdieu의 사회/문화적 자본(예: 관리 계층 및 도메인 지식)이 특정 AI 프로젝트 위험을 정당화했으며 위험이 식별되고 완화되도록 하는 데 중요한 요인이라는 사실이 밝혀졌습니다. 이 연구의 결과는 이러한 관점이 위험 표현과 이러한 위험이 궁극적으로 AI 프로젝트 맥락에서 관리될 수 있는 방법에 영향을 미칠 수 있으므로 향후 연구에서는 다양한 사회적 및 문화적 관점을 탐구해야 함을 시사합니다.

### 1. 서론

2022년에 실시된 Gartner의 Data & Analytics Summit 설문 조사에 따르면, 인공지능(AI) 혁신 리더의 44%만이 AI 프로젝트에서 가치를 볼 수 있다고 합니다. Gartner는 2021년 설문 조사에서 AI 프로젝트의 54%가 파일럿에서 프로덕션 환경으로 진행될 것이라고 예측했습니다. 즉, AI 프로젝트의 46%가 실패한 것입니다. 2019년 VentureBeat 설문 조사에 따르면 AI 프로젝트의 13%만이 프로덕션에 도달할 수 있었습니다(Saltz & Krasteva, 2022).

최근 몇 년 동안 AI(및 더 광범위한 데이터 과학 분야) 프로젝트 실패라는 주제는 다양한 관심 분야의 학자들로 부터 상당한 주목을 받았습니다. 많은 사람들이 데이터 과학, 머신 러닝, AI라는 용어를 서로 바꿔 사용하지만, 이러한 용어에는 미묘한 차이가 있습니다.

데이터 과학은 다양한 분석 기술을 사용하여 데이터에서 지식을 도출하는 데 중점을 둔 광범위한 분야입니다. 머신 러닝은 데이터의 하위 집합입니다.

과학은 특히 알고리즘을 사용하여 데이터에서 학습하고 예측을 수행합니다. 인공지능(AI)은 머신 러닝을 포함하는 포괄적인 도메인이며 다양한 작업에서 인간의 능력을 모방하거나 능가하는 시스템을 만드는 것을 목표로 합니다(Yeturu, 2020).

지난 40년 동안 정보 시스템(IS) 실패에 대한 상당한 양의 문헌이 축적되었습니다. IS 학문은 IS 실패에 기여하는 결정 요인의 세 가지 영역, 즉 사람, 조직 및 기술로 구성되어, 이 세 가지 모두에 프로세스가 기반을 두고 있습니다(Alharthi, Krotov, & Bowman, 2017).

AI(그리고 보다 일반적으로 데이터 과학) 프로젝트 실패는 앞서 언급한 IS 드라이버에 의해 발생한다고 가정할 수 있습니다. 실제로 데이터 과학 시스템의 선제적 실패의 주요 드라이버 중 하나는 기술 중심적 위험(Boyd, 2021)으로, 이는 프로젝트 실패의 주요 드라이버라는 측면에서 다른 IS 프로젝트와 일치합니다. IS 학문에 나타나지 않는 다른 주요 드라이버는 "성공적으로" 배포된 머신러닝 프로젝트에서도 차별적인 결과를 초래할 수 있는 사회적 및 윤리적 위험입니다(Atkinson, Crawford & Ward, 2006).

85명의 지식 근로자를 대상으로 실시한 조사에 따르면 실패에도 불구하고 데이터 과학 실무자는 실패를 프로젝트 추진에 방해가 되는 것으로 인식하지 않았습니다. 즉, 실패 위험은 잠재적인 투자 수익보다 덜 중요했습니다(Challen et al., 2019). 다른 연구에서 데이터 과학/AI 프로젝트 실패의 두드러진 이유는 달성 불가능한 기대, 모호한 목표, 제한된 인재, 데이터 문제, 기술에 대한 과도한 의존, 비효율적인 배포 및 유지 관리 계획과 관련이 있었습니다(Karacsony, 2022).

이러한 이유는 프로젝트 실패가 실증주의적이고 기능주의적 패러다임으로 정의될 수 있다는 개념과 일치합니다. 이러한 관점에서 시간, 비용 및 목표의 수행적 중요 실패 요인(CFF)으로 실패를 정의할 수 있습니다(Santos, Reis Neto, & Verwaal, 2018). 그러나 구조화된 PMBoK(Project Management Body of Knowledge) 기준으로 성공적인 프로젝트로 볼 수 있는 것은

사회기술적 관점에서 보면 실패로 간주될 수 있다.

예를 들어, 디자인 정의 학자이자 활동가인 콘스탄자-초크는 공항에서 남성과 여성의 정체성만 식별할 수 있는 스캐닝 아티팩트의 '성별 이분법의 사회기술적 재생산'(Costanza-Chock, 2018)을 강조합니다. 콘스탄자-초크는 '편차와 위험을 평가하는 데이터베이스, 모델, 알고리즘은 모두 이분법적이고 시스노르마틱하다'고 언급합니다. 마찬가지로 유색인종, 무슬림, 이민자, 장애인은 하이엔드 머신 러닝 기반 스캐닝 시스템으로 인해 더 높은 사회적 위험에 직면합니다(Challen et al., 2019; Costanza-Chock, 2018).

머신 러닝 시스템이 '성공적'으로 간주되었지만 사람들에게 차별적인 결과를 초래한 또 다른 사례 연구는 여성에 대한 성 편견을 보인 Apple 카드 사건에서 예시됩니다. 이 상황에서 소프트웨어 개발자이자 덴마크 기업가인 David Heinemeier Hansson은 자신의 Apple 카드 지출 한도를 배우자의 지출 한도와 비교한 결과, 배우자가 더 나은 신용 점수와 다른 기준을 가지고 있었음에도 불구하고 신용 한도 증가 요청이 거부되었다는 것을 알게 되었습니다(Vigdor, 2019).

이 상황에서 Apple 카드의 머신 러닝 신용카드 알고리즘은 처음에는 성공으로 여겨졌지만, 추가 분석을 통해 사회기술적 문제가 확인되었습니다. 간단히 말해, Apple 카드 사례 연구에 관련된 위험은 평판적, 윤리적, 사회적이었습니다.

위의 예는 사회기술 시스템이 성공적이더라도 사회적, 평판적, 법적, 개인정보적 위험을 지속시키는 경우 프로젝트 실패로 간주될 수 있음을 보여줍니다.

이는 AI 프로젝트의 위험이 어떻게 정의되는지, 어떤 위험이 정당화되는지에 대한 중요한 질문을 제기합니다. 다시 말해, *AI 프로젝트 실행 중에 고려해야 할 위험을 식별하는 사람은 누구입니까? AI 위험 관리 프로세스에서 고려되지 않는 위험은 무엇입니까?* 합법화는 법과 합의와 관련된 라틴어 'legitimus'에서 유래했습니다. 제도적 설정에서 사회적 관행의 합법화는 일반적으로 권위 있는 위치를 차지하는 사회적 행위자에 의해 수행됩니다. 이러한 사회적 행위자는 정치적 목표를 달성하기 위해 기술적 어휘를 통해 상징적 권력을 나타냅니다(Alharthi, Krotov &

보우먼, 2017). 이를 염두에 두고, 이 논문의 포괄적인 연구 질문은 다음과 같습니다.

*AI 프로젝트 실행 및 배포 중에 데이터 과학 실무자들은 실패 위험을 어떻게 표현합니까?*

다음 섹션에서는 정보 시스템 학문이 기능주의적 관점을 통해 AI 실패 위험을 정의하는 방법에 대한 논의를 확장합니다. 그런 다음 논문은 연구 결과 섹션에서 학문을 사회 자본 및 문화 자본과 연결하여 데이터 과학 실무자가 다양한 프로젝트 구성 요소의 행위와 사회/문화 자본(예: 교육 자격 및 직무 역할)에 따라 위험을 표현하는 방식에 대한 주요 주제를 강조합니다.

## 2. AI 프로젝트 실패 위험에 대한 기존 문헌

### 2.1. AI 프로젝트 실패 위험

IS 학문 분야에서 AI 프로젝트 실패 위험 요인을 파악한 연구는 아직 거의 없습니다. IS 학문 분야에서 AI/데이터 과학 프로젝트의 다른 많은 주요 실패 요인 중 일부는 다음과 같습니다. (1) 불분명한 비즈니스 요구 사항, (2) 비효율적인 커뮤니케이션 채널, (3) 손상된 데이터 품질, (4) 관련 인재 부족, (5) 확장 여지가 없는 엄격한 프로젝트 계획(Lai, 2017).

예를 들어, 데이터 과학 전문가를 대상으로 한 델파이 연구에서는 PMI 구조에 따라 데이터 과학 프로젝트 실패 위험을 다음과 같이 분류했습니다. *기능 범위, 프로젝트 관리, 운영 관리, 기술, 품질, 자원, 주변 환경, 법률, 커뮤니케이션, 조직 및 기타*(Joyce et al., 2021). 델파이 설문 조사의 내용 분석 중 가장 두드러진 주제는 모호하고 부정확한 질문으로 시작된 문제의 공식화였습니다. 다른 주제는 프로젝트 범위 부족, 데이터 품질 저하, 사양 오해, 인재 부족, 개인정보 침해, 모델 분석 비효율성, 의사 소통 오류, 모델 투명성 등과 관련이 있었습니다.

기술적으로 수행된 또 다른 델파이 연구 데이터 과학 실무자(Chapman, 2000) 전략적 전망의 부재, 변화 관리 및 윤리적 문제와 관련된 주제 외에도 유사한 주제를 확인했습니다. 이 델파이 연구에서 윤리적 우려 사항이 순위 순서의 마지막에 배치되었다는 점은 주목할 만합니다.

다른 연구 조사에서는 개발 위험, 마감일 지연, 리더십 지원 부족(Martínez-Plumed et al., 2019)과 거버넌스 정책 부족, 이질성, 데이터 크기(Boyd, 2021)에 초점을 맞춘 주제를 확인했습니다. 마지막으로 효과적인 프로젝트 관리 방법론의 부족은 AI 프로젝트 실패의 주요 원인 중 하나로 지적되었습니다(Saltz & Krasteva, 2022).

그러나 위험에 대한 규범적 정의에서 벗어나는 위험의 다양한 서사는 간과되었습니다. AI 프로젝트의 잠재적인 기술적 및 기능적 결함에 대한 관심이 높아졌음에도 불구하고, 프로젝트 실행 중 실패 위험을 데이터 과학 실무자가 어떻게 표현하고 해석하는지에 대한 중요한 질문은 광범위하게 탐구되지 않았습니다.

**2.2. NIST AI 위험 관리 프레임워크** 정부 기관을 포함한 조직에서는 위험 관리 프레임워크(RMF)를 통해 AI 프로젝트의 위험을 관리하기 위한 노력이 있었습니다(Saltz & Lahiri, 2020). 예를 들어, 1월 26일, 2023, 공공 및 민간 기관과 협력하여 NIST는 부문에 독립적인 인공지능 위험 관리 프레임워크(AI RMF 1.0)를 출시했습니다(NIST, 2023). 전반적으로 이 프레임워크는 AI 프로젝트의 위험 관리에 대한 사고 과정을 위한 디딤돌입니다.

간단히 말해, AI NIST RMF는 불리한 사건의 확률과 결과로 위험을 정의합니다. ISO 31000:2018의 위험 정의와 일치하는 AI NIST 프레임워크는 AI 위험의 부정적 결과를 최소화하려고 할 뿐만 아니라 삶의 웰빙과 일치하는 긍정적 사건을 탐구합니다(NIST, 2023). 이 프레임워크는 (1) 개인, (2) 기관, (3) 전체 서식지에 대한 세 가지 위험 범주를 인식합니다. 위험은 사회적 위험에서 평판 위험, 기후 위험까지 다양합니다. RMF는 전체(종단 간) 프로젝트 수명 주기에 걸쳐 아티팩트의 테스트, 평가, 검증 및 검증(TEVV)을 제안합니다. 전반적으로 NIST AI RMF의 핵심 기능은 네 가지입니다. 위험 요소가 매핑되는 내용에 따라 통제를 설정하는 위험 관리 문화를 관리하고, 식별 후 위험을 측정 또는 평가하고, 마지막으로 위험을 우선 순위 지정하고 관리하는 것입니다. 또한 이 프레임워크는 사회적 행위자의 집단적 책임을 통해 위험 관리에 대한 일반적인 지침을 제공합니다.

그러나 이 프레임워크는 계획 및 설계, 데이터 수집 및 처리, 구축, 검증, 배포, 모델의 모니터링 및 영향 평가에 이르기까지 단계를 탐색하는 '방법'에 대한 지침을 제공하지 않습니다. 마찬가지로 신뢰성에서 타당성, 안정성, 안전성, 보안, 복원력, 투명성, 설명 가능성, 개인 정보 보호, 공정성에 이르기까지 AI 모델의 '필수' 특성은 ISO 정의와 함께 제공됩니다. 위험에 대한 정의는 규범적이며 '좋은' AI 시스템의 이상을 달성하는 방법에 대한 지침은 제공되지 않습니다. 다시 말해, ISO의 표준 위험 정의를 활용하여 사회적,

위험에 대한 개인 차원의 표현 방식에 변화를 줄 수 있는 문화적, 정치적 맥락.

## 2.3. 이론적 기초

### 2.3.1. 부르디외의 사회자본

Bourdieu는 사회적 자본을 사회적 관계와 그룹 소속을 통해 부여된 권력과 연관시킵니다. 다시 말해, 사회적 자본은 직원들이 직업 및 비즈니스 영역에서 구축하는 네트워크와 관계를 통해 시작됩니다. 사회적 자본은 직장 내 개인, 규제 기관, 협력 파트너 및 고객 간의 다른 새로운 상호 작용의 결과입니다(Salajegheh & Pirmoradi, 2013). 사회적 자본은 또한 상징적인직함, 직함, 사회적 검증을 통한 자본(Bourdieu, 2018).

AI 프로젝트의 맥락에서 우리는 확장된 프로젝트 팀의 구성원인 참여자의 견해를 살펴봅니다. 참여자 그룹에서 일부는 관리직을 맡고 다른 일부는 독립적인 기여자 직위를 맡거나 주제 전문가입니다. 이러한 참여자는 어떤 역량과 형태로든 AI 프로젝트 실행에 기여합니다.

### 2.3.2 부르디외의 문화자본

Bourdieu에 따르면, 문화 자본은 사회 엘리트가 사회에서 더 높은 사회적 지위를 얻는 데 유리한 지식과 지적 능력을 말합니다(Santos et al., 2018; Bourdieu, 2011). 가장 중요한 자본 형태 중 하나로 강조되는 문화 자본은 문화적 이해, 태도, 데이터 과학 실무자 참여의 특정 영역에서 중요한 유물을 포함한 다양한 문화적 자원을 포함합니다(Levy & Reiche, 2018). 문화 자본과 사회적 위계는 복잡하게 얽혀 있으며, 서로 밀접하게 기능하여 개인과 집단을 사회 구조 내에서 다양한 위치로 분류하는데, 이는 각자의 자본 자원 부여에 따라 결정됩니다.

이 프로젝트와 관련하여, 우리는 공공 및 민간 기관의 주제 전문가, AI 프로젝트 관리자, 위험 관리자, 데이터 과학자, 전략 입안자를 인터뷰하여 위험에 대한 그들의 관점을 파악했습니다. 이러한 "사회적 엘리트"는 계층적 구조의 일부이거나, 주제 전문성이 직함을 대체하는 평면 구조의 일부입니다.

## 3. 방법론

이 질적 연구에서 우리는 AI 프로젝트 팀 구성원의 프로젝트 위험과 배포에 대한 다양한 관점과 표현을 이해하는 데 관심이 있었습니다.

AI 프로젝트에 참여한 모든 참여자는 공공 및 민간 부문의 다양한 산업에서 선정되었습니다. 데이터 과학 실무자에게는 자신을 데이터 과학자로 분류할 기회가 주어졌다는 점이 주목할 만합니다. '데이터 과학자'의 프로필을 우회하기 위해 문헌에서 차용한 정의는 없었습니다. 반구조화된 인터뷰에 참여한 모든 참여자는 일반적으로 데이터 과학 실무자라고 불렸습니다. 마찬가지로 참여자는 언급된 차이점에도 불구하고 AI, 데이터 과학 및 머신러닝 개념을 서로 바꿔 사용할 수 있었습니다.

Bourdieu의 문화적 자본을 사용하여 이 연구는 구체화된 문화적 자본과 기관적 문화적 자본(Levy & Reiche, 2018)이 어떻게 기관을 AI 실무자에게 요청하여 위험을 표현하고 이어서 정당화하는지 살펴보았습니다. 사회적 자본은 데이터 과학 실무자가 AI 프로젝트 위험을 정당화하도록 설득되는 방식을 확인하는 렌즈로 사용되었습니다.

제도화된 문화 자본은 학위와 같은 인정된 자격과 전문 지식 및 기술을 모두 포함하는 것으로 여겨졌습니다. 이러한 명시적 또는 암묵적 자격 증명은 구체화된 문화 자본의 중요성을 검증하는 기초 역할을 했습니다.

이 연구를 위한 데이터 수집은 공공 팀 협업 도구, 소셜 미디어 채널 및 공공 전문가 네트워크에 포스터와 메시지를 배포하는 것으로 시작되었습니다. 연구 기준을 충족하는 데이터 과학 종사자만 모집되도록 실사를 거쳤습니다. 이 연구를 위해 선택된 초기 연락처는 인터뷰를 위해 다른 관련 잠재 참여자의 연락처를 요청한 첫 번째 연결 노드가 되었습니다. 다시 말해, 이 연구를 위한 데이터 과학 종사자를 수집하기 위해 추천 프로세스 또는 스노우볼 샘플링이 사용되었습니다(Parker, Scott & Geddes, 2019).

아래 표는 인터뷰를 위해 선정된 16명의 AI 실무자에 대한 설명을 제공합니다.

표 1. 16명의 학력 및 근무 배경 참가자들

ID	성별	역할	위험 관리 경험 (년)	교육	일하다 배경
DS1	중	감독 - 일제 포함	10	미시시피	지능 분석, 운영 위험

					관리
DS2	중	부사장 - 전략적 사업	20	박사학위	데이터 과학, 일제 포함
DS3	중	부사장 - 데이터 & 인공지능	17	미시시피	미국 해군 학원, 분석 및 AI
DS4	중	부사장 - 오토메이션 그리고 해석학	1	학사	데이터 분석, 사업 지능, 데이터웨어하우스
DS5	중	데이터 과학자 그리고 위험 관리자	10	박사학위	은행 규제 위험과 관련된 관리
DS6	중	관리자 - 글로벌 데이터 관리	10	경영학 석사	재정적인 산업 및 전문적인 컨설팅
DS7	중	부사장 - 데이터 과학	8	박사학위	재원 산업, 모델 위험, 고급 해석학
DS8	중	대리인 감독	6	학사	위험 관리, 프로젝트 관리, 그것
DS9	중	어시스턴트 부사장	6+	박사학위	데이터 분석, 관리 컨설팅
DS10	중	임원 감독	12-15	미시시피	신용 위험
DS11	중	시니어 리스크 관리자	20	학사	IT 감사, IT 위험 관리
DS12	중	위험 데이터 해석학 건축가	7	경영학 석사,	프로젝트 관리, 사업 지능
DS13	중	연관짓다-모델링	3	미시시피	평가하다 모델 위험
DS14	중	관리자-데이터 과학	학습 직장에서	미시시피	분석적 솔루션 영업팀
DS15M (15명제)		관리자-제조업체 엔지니어 해석학	학습 직장에서	박사학위	해석학 하부 구조
DS16M (미국)		감독-미르	7+	MBA, MS 추천	ns 및 개인화

표 1에서 볼 수 있듯이, 연구에 참여할 여성 참가자를 찾을 수 없었습니다. 게다가, 많은 참가자가 매우 경험이 많았고, 종종 고위 경영진의 일원이었습니다. 다음 분석 및 결과 섹션에서는 개인의 위험 표현이 기관에서 정의한 위험과 어떻게 다를 수 있는지 강조합니다.

## 4. 데이터 분석

주제 분석 또는 TA는 일반적으로 질적 연구에서 관련된 렌즈나 패턴을 수집하는 데 사용됩니다. 주제 분석 프레임워크는 5단계로 구성됩니다(Castleberry & Nolen, 2018): *모임*,

*해체하다*, *재구성*,  
*해석하고 결론에 도달함*.

주제 분석의 첫 번째 단계에서는 반구조화된 인터뷰를 통해 수집된 데이터를 필사했습니다. 16명의 남성 데이터 과학 실무자와의 인터뷰는 IRB 승인 후 중 통화로 진행되었습니다. 인터뷰는 30분에서 120분까지 진행되었습니다. 인터뷰 전에 연구의 전제를 참가자가 알고 있는지 확인하기 위해 동의서를 보냈습니다. 데이터를 수집한 후 참가자는 영수증으로 익명화되었습니다. 연구의 두 번째 단계에서는 인터뷰 필사본을 해체했습니다. 즉, 텍스트 데이터를 더 광범위한 구성 요소 또는 주제로 세분화했습니다. 구성 요소는 두 저자가 독립적으로 수집했습니다. 결과의 일치와 불일치를 논의하기 위해 주간 통화를 예약했습니다. 세 번째 단계에서는 해체된 주제를 더 작고 유사한 주제를 결합하여 재구성했습니다. 차이점을 조정하기 위해 브레인스토밍 통화를 실시했습니다. 네 번째 단계이자 그에 따른 다섯 번째 단계에서는 귀납적 접근 방식을 통해 더 넓은 범위의 주제를 해석하고 좁은 범위의 주제를 포괄하였으며, 최종적으로 이 연구에 적합한 주제를 도출했습니다.

## 5. 결과

AI 프로젝트 중에 발생한 실패 위험에 대한 여러 가지 표현은 인터뷰 동안 참가자들에 의해 공유되었습니다. 다시 말해, 참가자들은 AI 프로젝트 위험과 배포 위험에 대한 의미를 어떻게 이해하고 부여했는지 공유했습니다. 개별 표현은 종종 위험 표준 및 정책의 규범적 기관 및 규제 코드의 영향을 받았습니다. 그러나 기관 위험과 관련된 참조점이 거의 또는 전혀 없는 다른 관점이 확인되었습니다.

이 섹션에서는 데이터 과학 실무자들의 다양한 관점에 대한 개요를 제공하며, AI 프로젝트 실행 및 배포의 위험을 해석하는 방식 측면에서 설명합니다. 아래 표 2는 다양한 위험 집중 영역에 대한 스냅샷을 제공합니다.

표 2. AI 프로젝트 실행의 주요 주제 및 배포 위험

위험 집중	간단한 설명	조직 (ID#)
윤리적 위험	법정 사건, 평판, 모델 차별, 편향, 과적합	DS1, DS2, DS7, DS9
블랙박스 모델	설명 가능성, 투명성	DS1, DS7, DS9, DS16
데이터 개인정보 보호	내부 위험, PII, 데이터 분류	DS1, DS6, DS7, DS12
데이터 저장	데이터 레이크, 데이터 팩토리, 데이터 웨어하우스, 데이터 문화, 데이터 전처리, 데이터 포매팅	DS4, DS5, DS8, DS16

재정적인 위험	모기지 및 포트폴리오 관리, 자산 관리, 확률적 충격, 몬테카를로 시뮬레이션, 거시경제 지표, 일일 또는 주간 시장 변동성, 투자 레버리지	DS3, DS5
성공 기준	사용자 경험, 사용자 추천,	DS3, DS8, DS16

또한, 표 3에서 볼 수 있듯이 분석을 통해 대리권과 사회/문화 자본이 해당 위험의 식별과 완화에 어떤 영향을 미치는지에 대한 몇 가지 통찰력을 확인했습니다.

표 3. AI에 영향을 준 사회/문화 자본 프로젝트 실행 및 배포 위험

위험 집중	대리의 영향과 사회/문화적 자본
윤리적 위험	소비자의 대리권 - 윤리적 위험을 사전에 식별합니다.  윤리적 위험 인식 - 팀을 이끈 고위 이해 관계자에게 달려 있습니다.
블랙박스 모델	소비자의 대리 - 모델 행동에 대한 적극적인 설명을 촉진합니다.
데이터 개인정보 보호	정부 기관 - 위험 식별/관리는 규정을 통해 이루어 집니다.
데이터 저장	문화적 자본(즉, 도메인 지식) - 조직이 이러한 위험을 인식하고 관리하도록 촉진합니다.
재정적인 위험	재무 위험 관리자의 기관 - 모델의 재무적 영향을 평가하는 방법을 결정합니다.  정부 기관 - 위험 식별/관리는 규정을 통해 이루어 집니다.
성공 기준	클라이언트의 대행 - 위험을 줄이기 위한 성공 기준 정의

### 5.1. AI 프로젝트의 윤리적 위험

윤리적 위험은 모델 행동으로 인해 조직 평판에 잠재적으로 부정적인 영향을 미치는 실질적인 위험으로 해석되었습니다. 예를 들어, DS1은 정부 방위 기관에서 근무했으며, 윤리적 위험을 기관에 대한 법적 및 평판적 영향과 연결한 AI 전략 책임자였습니다. ... 만약 우리가 법정에 서게 되거나, 기계가 내린 인사 결정에 대해 많은 사람들이 우리를 법정에서 고소한다면, 우리가 하는 일이 윤리적이고 합법적인지 확인하기 위해 무엇을 해야 할까요? 그리고 그것이 기관에 어떤 종류의 전략적 위험을 초래할까요? 그래서 저는 프로젝트를 적용할 때 이런 종류의 연방 위험 수준을 고려해야 합니다... (Lahiri & Saltz, 2022) 마찬가지로 은행의 제3자 컨설턴트로 일했던 DS9는 윤리적 위험을 대출 승인에 대한 결정에서 지속되는 편견으로 해석했으며, 이는 법정에서 변호가 필요할 수도 있다고 생각했습니다.

...우리는 [은행 이름]과 프로젝트를 진행 중입니다. 지금은 고객과 문제가 있습니다. 고객에게 대출이 승인되지 않을 때마다 고객이 실제로 법원에 가서 대출이 승인되지 않은 이유를 묻기 때문입니다. 어쩌면... 편견이 있을 수도 있습니다.

다른 예로, 제조 대기업에서 수석 윤리학자 겸 팀 관리자로 일하는 DS2는 개별적으로 위험을 정의하고 위험 대응책을 실행할 수 있습니다. DS2가 강조하듯이, 이러한 조치는 데이터 과학 팀 구성원의 합의 없이 취해질 수 있으며, 단순히 "프로젝트를 수행하지 않는 것"일 수 있습니다. 다시 말해, 권력 구조의 상당 부분인 DS2는 경영진에게 가지 않고도 위험의 소유권을 가질 수 있습니다.

하지만 윤리적 위험은, 저는 제 자신을 위험 감수자로서 생각합니다... 그래서... 제가 그냥 거절한 프로젝트들이 있습니다. 그리고 저는 팀원들에게 물어보지도 않고, 그냥 안 된다고 말했습니다... 이건 윤리적으로 용납할 수 없는 일이에요. 우리는 그걸 하지 않을 겁니다, 끝...  
그러나 모델 위험 팀을 이끈 다른 참여자 DS7은 감사의 기여가 모델 보고의 맨 위에서 발생한다고 말했습니다. 그러나 모델 위험에 대한 감사 외에도 모델을 모니터링하기 위한 통합 또는 중앙 집중화된 정책과 표준을 갖는 것이 중요했습니다.

...요즘은 모델 위험과 모델 거버넌스에 관심을 갖는 사람이 많습니다. 업계 자체에서도 많은 논의가 있죠, 맞죠? 모델을 식별하는 방법이 차별적이었어요, 알다시피, 직접적으로는 아니지만 간접적으로요. 그럼, 어떤 종류의 바이어스 매트릭스를 모델에 적용해야 할까요? 그래서, 저는 여기서 많은 범위와 해야 할 일이 남아 있다고 봅니다. 고객에게서 데이터를 생성하는 방법, 저장하는 방법, 저장하지 않는 방법에 대한 매우 견고한 원칙이 있기 때문입니다. 우리는 이에 대한 좋은 정책을 가지고 있습니다. 하지만 우리가 정말 놓치고 있는 것은 좋은 정책과 통합된 표준, 그리고 모델을 모니터링하고 잘못된 일을 하지 않도록 하는 도구 측면입니다..."참가자는 경영진부터 직원 수준까지 변화를 가져올 수 있는 상향식 권한을 부여하는 효과적인 머신 러닝 모델 정책을 갖는 것이 효과적이라는 점을 강조합니다.

위의 서술은 윤리적 위험이 회사의 평판과 일치한다는 것을 보여줍니다. 사회의 사용자가 조직이 바람직하지 않은 편견에 대해 책임을 지도록 법적 도움을 받을 수 있다는 우려가 있습니다. 이는 모델 윤리와 관련하여 제한된 공식적 의무에도 불구하고 사용자는 윤리적 위험을 최소화하는 데 도움이 되는 기관을 가지고 있다는 것을 강조합니다.

또 다른 주목할 만한 주제는 도메인 전문가와 경영 실무자의 문화적, 사회적 자본을 통한 위험의 합법화와 관련이 있습니다. DS2는 자본을 획득한 팀 관리자였으며 팀의 위험 관리 프로세스에 대한 변경 및 수정을 시행하는 기관이었습니다.

간단히 말해, 문화적 자본을 권력의 지표로 간주하면 사회적 자본은 AI 프로젝트 구성원을 통해 획득되었습니다. 윤리적 위험에 대한 인정은 종종 팀을 이끄는 고위 이해 관계자에게 달려 있었습니다. 다시 말해, 윤리적 위험을 인정하는 프로세스는 일반적으로 관리 팀의 데이터 과학 실무자에게 달려 있었습니다. 예를 들어, DS1은 팀 구성원의 관점을 염두에 두고 윤리적 위험을 합리화했지만 DS2의 경우 합법화는 개인적입니다. 이 주제는 또한 Bourdieu에 따르면 분야인 프로젝트 전반의 사회적 행위자의 해석을 탐구하는 데 대한 중요한 질문을 생성합니다(Levy & Reiche, 2018).

## 5.2 블랙박스 모델

인터뷰 동안 데이터 과학 실무자들은 데이터 과학 모델의 불투명성에 대해 우려했습니다.

예를 들어, DS9는 모델 설명 가능성의 부족으로 인한 위험을 표명했습니다. 아래 인용문은 데이터 과학 실무자의 문화적 자본을 방해하는 블랙박스 모델의 모호함을 반영합니다. 다시 말해, 기술적 기술과 지식의 자본은 블랙박스를 완전히 설명하는 데 필요한 수준이 아니며, 간단한 언어나 다른 모델을 사용하여 일반 시민이 모델을 소화할 수 있도록 하려면 더 많은 작업이 필요합니다. 더욱이 소비자는 법적 지원을 받아 데이터 과학 모델의 편견에 반대할 수 있는 권한을 가지고 있으며, 이는 설명 가능한 모델에 대한 필요성을 다시 강화합니다. 간단히 말해, 프로젝트와의 권력 갈등은 기득권 소비자와 같은 외부 세력과 관련이 있습니다.

...우리는 은행과 프로젝트를 진행 중인데...은행은 고객과 문제가 있는데, 대출이 고객에게 승인되지 않을 때마다 고객이 실제로 대출이 승인되지 않은 이유를 묻기 위해 법원에 갈 수 있기 때문입니다...아마도 편견이 있을 것입니다...대출이 승인되지 않은 이유를 설명하는 것은 큰 과제입니다.모델이 블랙박스와 같기 때문입니다...하지만 고객에게 이것이 우리가 대출을 제공할 수 없는 이유라고 설명하는 방법은...좋아요, 이것은 우리가 여전히 작업하고 있는 부분이고 큰 과제가 거기에 있습니다...

다른 유형의 블랙박스 챌린지는 다음과 같습니다. 위험을 식별한 참여자 DS1이 공유함

데이터 과학 전문가가 프로젝트 워크플로 중에 이해관계자 및 경영진과 소통하기 위해 가끔 사용하는 모호하고 기술적인 언어입니다.

“...그래서, 우리가 사람들에게 전달하려고 하는 내용 중 일부 언어[경영진]가 그들의 제품으로 무엇을 해야 하는지에 대한 내용을 읽고 있을 때...우리는 많은 기술 용어를 사용하여 설명하고 있습니다...그래요...당신은 정말 똑똑해 보이네요. 축하합니다! 하지만 아무도 그 정보를 사용할 수 없어요. 그 의미를 이해하지 못하기 때문이죠...”(라히리 & 샬츠, 2022).

### 5.3 데이터 개인정보 보호

많은 머신 러닝 프로젝트는 이기종이며 종종 방대한 양의 데이터를 사용하여 지식 통찰력을 생성합니다. 조직에서 개인 정보 보호는 민감한 정보를 무단 액세스 및 데이터 분류의 거짓 양상으로부터 보호하는 측면에서 가장 중요해집니다.

DS6는 거버넌스 정책 및 정부 법률과 일치해야 하는 데이터 분류 및 개인 정보 보호 관점에서 발생하는 위험을 명확히 밝혔습니다. DS6에 따르면 위험은 PII의 잘못된 분류 또는 데이터 분류가 표준 데이터 분류 규칙에서 벗어날 때 발생했습니다. 데이터 유출의 맥락에서 DS6는 데이터 분류에 대한 GDPR 의무를 준수하지 않는 위험을 강조했습니다.

“...저는 요즘 가장 중요한 것이 바로...데이터 프라이버시라고 생각합니다. 그래서 데이터 프라이버시는 지난 3~4년 동안 GDPR과 그 뒤안길, 그리고 다른 지역의 버전들과 함께 큰 문제가 되었습니다. 그래서...데이터를 어떻게 보관하고, 다른 사람들의 데이터를 어떻게 사용하고, 얼마나 오랫동안 사용할 것인지, 그리고 누구에게 줄 것인지에 대한 위험이 요즘 매우 중요해지고 있습니다...”(라히리 & 샬츠, 2022).

마찬가지로 대형 투자 은행에서 근무한 DS7도 개인정보 보호 위험에 대한 우려를 공유했습니다. “...데이터 개인정보 보호 위험부터 시작하여...데이터와 관련된 정책 및...웨어하우스에 데이터를 보관하는 것, 그리고 기술 위험...그래야 툴링으로 인해 데이터가 누출되지 않습니다...”

따라서 데이터 개인정보 보호 위험과 관련하여 이러한 데이터 개인정보 보호 위험을 식별하고 관리하는 데 있어 가장 중요한 힘은 표준과 정책에 의해 주도되었습니다.

예를 들어, DS6는 데이터 과학 실무자가 프로젝트를 실행하는 동안 규정과 표준을 고려해야 하는 이유를 공유했습니다. 궁극적으로 이 AI 프로젝트 위험의 표현과 완화를 지시하는 정부에서 수립한 정책을 준수하려는 욕구(또는 의무)가 있습니다. 다시 말해, 이

위험은 본질적인 도덕적 가치보다는 권위와 표준적인 의례로 인해 발생했습니다.

### 5.4 데이터 저장

데이터 저장 위험은 예측 모델을 구축하는 데 사용되는 데이터가 여러 개의 종종 호환되지 않는 조직 및/또는 기술적 "사일로"에 저장되는 것과 관련이 있습니다. 이로 인해 사용 가능한 모든 데이터를 완전히 활용하기 어렵습니다.

예를 들어, DS5에 따르면 위험은 시스템 기반 포매팅 시스템과 호환되지 않는 데이터 불일치로 표현됩니다. 문제의 일부로, 일관되지 않는 데이터 포매팅은 위험 예측 프로젝트에서 문제로 간주되었습니다.

“...음, 이미 위험 측정의 일부인 특정 기능이 있습니다. 아시다시피, 일일 또는 주간 변동성, 투자에 사용되는 레버리지 양, 거시경제 지표... 많은 작업이 실제로 데이터를 로드하는 것입니다. 왜냐하면 데이터가 동일한 형식으로 제공되지 않기 때문입니다. 특히 날짜가 있는 날짜와 관련하여 서식 지정은 큰 문제입니다. 저장된 날짜는 모든 시스템에서 항상 동일한 것은 아닙니다...”

마찬가지로 DS4는 성공 기준이 있음에도 불구하고 조직이 종종 국경을 넘나드는 팀과 데이터 관련 위험을 발생시킨 분산된 데이터 저장소와의 갈등에 연루되었다고 강조했습니다. DS8은 또한 서로 다른 분류법을 가진 사일로화된 데이터 저장소로 인해 데이터 불일치가 발생한다고 믿었습니다. 위험은 데이터와 시너지를 생성하지 못하는 사일로화된 프로세스로 해석되었습니다. 우리는...저는...연방 정부가 우리 편에 두고 있는 가장 큰 분산되고 부적절한 데이터 센터를 가지고 있다고 말하고 싶습니다...우리는 8개의 서로 다른 프로세스를 사용하는 8개의 서로 다른 데이터 센터를 가지고 있고, 코더나 다른 어떤 것으로도 데이터 사전이 없습니다. 사실상 서부 개척시대와 같습니다...”

DS8 토큰의 다른 부분에서 DS8은 시스템 내에 프로젝트 문서가 없는 것처럼 보이는 위험을 합법화하기 위해 특정 언어적 선택을 사용했습니다. 이 언어는 문화적 자본의 상징적 언어로 위험을 합리화하기 위해 의도적으로 사용되었습니다.

“...저는 COBOL로 작성된 백본 시스템을 가지고 있는데, 실제로 고치는 방법을 아는 두 사람이 로드했습니다...그리고 그들은 둘 다 80대입니다. 그리고 아무도...한 명도 없습니다...코드가 어디에 쓰여 있는지 모르니다...이 사람들[80년대의 실무자]은 그들의 머리에 코드를 볼트로 고정해 놓았고...이것은 수년 동안 계속되었습니다! 그래서 지금, 제가 말했듯이, 4년 동안 비명을 지르고 벽에 머리를 부딪히고 스카치를 많이 마신 후에...그들[경영진]은 마침내 시작하자는 생각을 내렸습니다.”

글을 쓰는 것. 재미없다는 건 알지만, 중요한 일이에요...”

추가 조사를 통해 고립된 방식으로 일하는 것의 위험성은 조직 내에 위험 문화가 없다는 점이라는 점이 드러났습니다.

...우리는 다양한 입학 사정을 가지고 있고 실제로 위험 문화가 없습니다. 우리는 너무 위험 회피적이어서 연방 직원이 위험이라는 단어를 무서워하는 것도 웃기지 않습니다...

위의 서술은 위험에 대한 부정적인 감정을 표현합니다. 적어도 이 맥락에서 위험은 기회보다는 위협으로 간주됩니다. 또한 위의 주제는 위험을 정당화하는 과정에는 AI 프로젝트 위험을 숙고하고 관리하는 감정을 주입할 수 있는 문화도 필요하다는 것을 강조합니다.

### 5.5 재정적 위험

금융 위험과 위험 관리 거버넌스의 개념은 1950년대 중반부터 시장 보험과 함께 대중화되었습니다. BASEL II/III 협정, Sarbanes-Oxley, Solvency-II와 같은 추가 규제 의무는 금융 기관에 신용, 시장, 유동성 및 시장 위험의 추가 계층과 함께 규정 준수 및 자금 세탁 방지 (Winchester, Boyd, & Johnson, 2022)를 추가했습니다.

대형 금융 투자 기관에서 근무한 DS10은 데이터 분석, 프로세스 엔지니어링 및 고객 경험을 통해 신용 위험을 관리했습니다. DS10은 데이터 과학 위험을 모기지 및 포트폴리오 관리와 관련된 재무 위험과 연결했습니다. ... 일부 최상위 위험은 모기지 발행과 모기지 포트폴리오 관리 측면에서 파이프라인에 들어오는 것과 포트폴리오에 있는 것이 무엇인지입니다.

즉, DS10은 자본 수익과 신용 점수 세부 정보로 구성된 고객 포트폴리오의 재무 위험 관리를 관리했습니다. 이 데이터는 문제 또는 고객 관련 자본 위험을 이해하고 지식 통찰력을 위한 프로토타입을 생성하는 데 사용되었습니다.

...우리는 높은 수준이 문제가 무엇인지 이해하고, 고객과 인터뷰와 연구 인터뷰를 하는 것이라고 말할 수 있습니다. 내부 및 외부 이해 관계자가 있을 수 있으며, 그런 다음 연구를 수행하여 문제를 더 잘 이해한 다음 이해 관계자에게 분석 및 결과를 제안하여 동의를 얻습니다. 그런 다음 프로토타입을 만들고 챔피언을 내놓습니다.

이러한 위험 관리에는 위험이 진정한 위험인지 확인한 권력 구조의 이해 관계자와의 동의가 필요했습니다. 또한 투자 기관이기 때문에 위험은 특정 금융 규정을 준수해야 했습니다.

### 5.6 성공 기준

성공 기준은 예산 기준, 변화 관리, 명확한 비즈니스 목표와 같은 주제를 포괄하며, 이는 이전에 IS 문헌에서 확인된 바 있습니다(Varela & Domingues, 2022).

예를 들어, 민간 제조 회사에서 일했던 DS2는 모호한 사업 목표, 변화 관리 및 예산 제약으로 인해 발생하는 위험을 설명했습니다. 이러한 주제는 IS 학문과 잘 어울리며 데이터 과학 위험 맥락에서 유사한 문제가 발생할 수 있음을 강조합니다.

...데이터 과학과 관련된 위험은 매우 많습니다. 가장 분명한 것은 프로젝트 인용문이 실패한다는 것입니다. 문제가 무엇인지 알아내야 하고 위험이 있습니다. 사실, 이런 일은 우리가 원하는 것보다 더 자주 발생합니다. 의사소통이 잘못되어 원래 존재하지 않았던 문제가 해결되고, 원래 존재했던 문제가 해결됩니다. 그리고 세 번째 위험은 인공 지능을 따라야 하는 변경 관리 절차에 있습니다.

DS4는 위험을 조직 내 특정 사업 목표 또는 '성공 기준'의 부재로 정의했습니다. 다시 말해, DS4는 데이터 과학 실무자에게 '기본 진실'이 되는 성공 기준의 중요성을 설명했으며, 이에 대한 모든 편차는 위험으로 해석됩니다.

...위험을 계산하거나 이해하기 전에, 누구든 위험 프레임워크를 수립하기 전에, 주어진 프로젝트에 대해 가장 먼저 해야 할 일은 성공 기준이 무엇인지 확립하는 것입니다... 이 프로젝트에서 무엇을 얻으려고 하는가? 이 프로젝트가 성공했다고 말할 때는 언제인가?... 그리고 저는 여러분이 다른 많은 참여자에게 이 질문을하기를 권장합니다... 그들 대부분은 그렇게 하지도 않습니다...(라히리 & 샬츠, 2022)

또한 DS4는 성공 기준이 있음에도 불구하고 조직이 종종 국경을 넘나드는 팀과 데이터 관련 위험을 발생시킨 분산된 데이터 저장소와의 갈등에 연루되었다는 점을 강조했습니다. 이 내러티브는 실무자가 자신의 지식과 기술적 기술을 활용하는 것만으로는 충분하지 않으며 성공 기준을 통해 전달된 내용을 명확하게 이해하고 전달해야 한다는 점을 강조했습니다. 조화의 잠재적 부족(이해하지 못하거나 "성공"을 전달하지 못하는 갈등)은 프로젝트의 성공적인 실행을 방해할 수 있는 위험입니다.

이것은 설명합니다 왜 DS2 말하는 AI 프로젝트의 위험으로서의 오해의사소통. 다른 예로, DS6에 따르면 위험의 합법화와 위험 완화 조치는 해당 위험이



해석이 가능하고 실무자들에게 효과적으로 전달되었습니다.

## 6. 결론

이 질적 연구에서는 16명의 남성 데이터 과학 실무자를 대상으로 인터뷰를 실시하여 프로젝트 실행 중에 AI 프로젝트의 실패 위험이 개인 수준에서 어떻게 표현되는지 알아보았습니다.

이러한 실무자들이 활용한 문화적 자본은 그들의 교육적 배경과 도메인에서 보낸 업계 연도를 통해 만들어졌습니다. 실무자들은 대부분 고위 리더십 직위에 있었으며, 위험에 대한 각자의 관점을 가지고 있었고, 위험에 대한 제도적 정의와 동질화되었습니다. 위험의 표현은 기존 금융 규정, GDPR과 같은 데이터 법률 및 윤리적 위험에 대한 약한 주제의 영향을 받았습니다.

그러나 AI 프로젝트의 상위 리더들 사이에서도 다른 사람의 행위나 위험에 대한 내부적 본질적 이해에 따라 AI 프로젝트 실행 및 배포 위험을 표현하려는 시도가 있었습니다.

### 6.1 요약

데이터 과학 실무자와의 반구조화 인터뷰의 내용 분석 과정에서 윤리적 위험, 블랙박스 모델, 데이터 개인 정보 보호, 데이터 저장, 재무적 위험, 성공 기준이라는 여섯 가지 주제가 AI 프로젝트 위험에 대한 개별적인 표현으로 나타났습니다.

문화적 자본은 종종 위험을 정당화하기 위한 상징적 자본으로 표현되었고, 사회적 자본은 합의를 얻기 위해 표현되었습니다. 인터뷰 중에 AI 프로젝트 위험에 대한 개념을 정당화하기 위해 사회적 자본에 의존하지 않는 '위험 감수자'도 있었습니다.

본 연구의 범위가 팀 구성원의 권력 구조를 이해하는 것과 관련이 없었지만, 니콜리니의 숨인 및 줌아웃 렌즈(Nicolini, 2009)를 사용한 주제 분석 시에는 위험을 정당화하거나 비합법화하는 권력 갈등의 사례가 많이 있었습니다.

### 6.2 제한 사항 및 향후 작업

본 논문은 저희가 아는 한, 데이터 과학 팀원인 사회적 행위자들이 개인 수준에서 위험을 어떻게 표현하는지 탐구한 최초의 시도입니다.

그러나 이 연구의 참여자는 데이터 과학 분야의 전문가였습니다. 이와 관련하여 이 연구의 한 가지 주요 한계는 인터뷰한 실무자의 다양성이 부족하다는 것입니다. 따라서 향후 연구에서는 전문성이 낮거나 낮은 데이터 과학 프로세스 참여자를 탐색해야 합니다.

조직 내의 위치(즉, 이 연구에서 인터뷰한 사람들과 다른 문화적 자본). 다시 말해, 향후 연구에서는 다양한 계층, 성별, 인종 및 민족의 데이터 과학 실무자들의 AI 프로젝트 위험 표현을 탐구해야 합니다. 예를 들어, 해외 법인의 실무자와 백오피스 직원이 AI 프로젝트의 위험을 어떻게 식별하고 표현하는지 탐구합니다. 다른 예로, 향후 연구에서는 실무자의 성별이 AI 프로젝트 위험에 대한 인식과 표현에 영향을 미치는지 탐구해야 합니다. 이 연구의 또 다른 한계는 연구에 참여한 사람의 표본 크기가 작다는 것입니다. 따라서 향후 연구에서는 광범위한 데이터 과학 실무자를 대상으로 설문 조사를 통해 이러한 주제를 보다 광범위하게 탐구할 수 있습니다.

또한, 니콜리니의 숨인 및 줌아웃 툴킷은 반드시 권력 구조에 위치하지 않고 공통된 신념을 통해 위험 표현을 중재하는 데이터 과학 실무자의 사회적 관행을 분석하는데 사용될 수 있습니다(니콜리니, 2009). 마지막으로, 이 연구는 또한 과학 및 기술 연구 학자, 페미니스트 및 비판 학자들이 AI 프로젝트 위험이 다양한 인종, 민족 및 성별 실무자에 의해 어떻게 해석되는지 분석해야 한다고 제안합니다.

## 7. 참고문헌

- Aho, T., Sievi-Korte, O., Kilamo, T., Yaman, S., & Mikkonen, T. (2020). 데이터 과학 프로젝트의 신비 해체: 오늘날 데이터 과학의 사람과 프로세스에 대한 고찰. 제 품 중심 소프트웨어 프로세스 개선: 21회 국제 컨퍼런스, PROFES 2020, 이탈리아 토리노, 2020년 11월 25일-27일, 회의록 21(153-167쪽). Springer International Publishing.
- Alharthi, A., Krotov, V., & Bowman, M. (2017). 빅데이터 장벽 해결. Business Horizons, 60(3), 285-292.
- 아리스타, N., 코스탄자-초크, S., 가자비, V., 카이트, S., 클루스마이어, C., 루이스, JE, ... & 달링, K. (2021). 디자인 정의, AI, 그리고 지배의 매트릭스로부터의 탈출.
- Atkinson, R., Crawford, L., & Ward, S. (2006). 프로젝트의 근본적인 불확실성과 프로젝트 관리 범위. 국제 프로젝트 관리 저널, 24(8), 687-698.[19] Parikh, RB, Teeple, S., & Navathe, AS(2019). 의료 분야에서 인공 지능의 편견 해결. Jama, 322(24), 2377-2378.
- Bourdieu, P. (2011). 자본의 형태.(1986). 문화적 이론: 선집, 1, 81-93.
- Bourdieu, P. (2018). 자본의 형태. 사회학에서 경제생활의 (pp. 78-92). Routledge.
- 보이드, AE(2021). 교차성과 반사성—데이터 과학 프로세스를 위한 방법론의 식민지화 해체. 패턴, 2(12), 100386.

- Castleberry, A., & Nolen, A. (2018). 주제 분석 질적 연구 데이터: 말처럼 쉬운가요?. *Currents in Pharmacy Teaching and Learning*, 10(6), 807-815.
- Challen, R., Denny, J., Pitt, M., Gompels, L., Edwards, T., & Tsaneva-Atanasova, K. (2019). 인공지능, 편견 및 임상 안전. *BMJ 품질 및 안전*, 28(3), 231-237.
- Challen, R., Denny, J., Pitt, M., Gompels, L., Edwards, T., & Tsaneva-Atanasova, K. (2019). 인공지능, 편견 및 임상 안전. *BMJ 품질 및 안전*, 28(3), 231-237.
- 채퍼먼, P., 클린턴, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: 단계별 데이터 마이닝 가이드. *SPSS inc*, 9(13), 1-73.
- Collins, PH (1998). 싸움의 말: 흑인 여성과 정의를 위한 탐색(Vol. 7). 미네소타 대학교 출판부.
- Costanza-Chock, S. (2018). 디자인 정의, AI, 그리고 탈출 지배의 매트릭스에서. *디자인과 과학 저널*, 3(5)
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). 그만큼 데이터 볼륨에서 유용한 지식을 추출하기 위한 KDD 프로세스. *ACM 커뮤니케이션*, 39(11), 27-34.
- Gray, L. (2019). 집단적 목소리로: 발견 1955년부터 1970년까지 시카고 공공주택의 활동가 어머니들로 구성된 흑인 페미니스트 정보 커뮤니티.
- Gray, L. (2021). 사례 연구 문의 및 흑인 페미니스트 저항. *정보, 다양성 및 포용성 국제 저널*, 5(2), 71-83.
- 구스타브손, TK, & Hallin, A. (2014). 다시 생각하다 이분법: 프로젝트 관리 연구에서 "하드"와 "소프트" 사용에 대한 비판적 관점. *국제 프로젝트 관리 저널*, 32(4), 568-577.
- 존슨 3세, RG, & 렌데로스, H. (2020). 보이지 않는 인구와 #MeToo 운동. *공공행정리뷰*, 80(6), 1123-1126.
- 조이스, K., 스미스-도어, L., 알레그리아, S., 벨, S., 크루즈, T., Hoffman, SG, ... & Shestakofsky, B. (2021). 인공지능 사회학을 향하여: 불평등과 구조적 변화에 대한 연구 요청. *Socius*, 7, 2378023121999581.
- Kapitzke, C. (2000). 문화적 정보 기술 자본: 권력의 경계를 이동하다. *교육 및 정보 기술*, 5, 49-62.
- Karacsony, P. (2022). 태도 분석 헝가리 HR 전문가의 인공지능. *Naše gospodarstvo/우리 경제*, 68(2), 55-64.
- Lahiri, S & Saltz, J. 향상된 프로세스의 필요성 윤리적 데이터 과학 프로젝트를 위한 방법론. *IEEE ETHICS-2023: 글로벌 혁신 헬릭스의 윤리*[34]
- Börjesson, M. (2017). 2010년 국제 학생의 글로벌 공간. *민족 및 이주 연구 저널*, 43(8), 1256-1275.
- Lahiri, S., & Saltz, J. (2022, 1월). 위험 데이터 과학을 위한 관리 프로세스: 현재 관행의 격차. 제 55회 하와이 국제 시스템 과학 컨퍼런스 회의록.
- Lai, ST(2017). 반복적이고 증분적인 데이터 빅데이터 프로젝트의 위험 감소를 위한 품질 개선 절차. *J. Softw.*, 12(12), 945-956.
- Levy, O., & Reiche, BS(2018). 문화 정치 자본: 다국적 기업의 사회적 위계와 조직 구조. *인간관계*, 71(6), 867-894.
- Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernández-Orallo, J., Kull, M., Lachiche, N., ... & Flach, P. (2019). 20년 후의 CRISP-DM: 데이터 마이닝 프로세스에서 데이터 과학 궤적으로. *IEEE 지식 및 데이터 엔지니어링 저널*, 33(8), 3048-3061.
- Modrek, S., & Chakalov, B. (2019). The# MeToo 미국에서의 움직임: 초기 트위터 대화의 텍스트 분석. *Journal of medical Internet research*, 21(9), e13837.
- NIST AI, (2023). 인공지능 위험 관리 프레임워크(AI RMF 1.0).
- 니콜리니, D. (2009). 확대 및 축소: 공부 이론적 렌즈를 전환하고 연결을 추적하여 관행을 개선합니다. *조직 연구*, 30(12), 1391-1418. *Ozmen, ES*(2013, 3 월). 프로젝트 관리 방법론(PMM): PMM은 오늘날 조직에 어떻게 도움이 될 수 있을까?. *PMI 글로벌 콘그레스 EMEA*의 진행 중.
- Parker, C., Scott, S., & Geddes, A. (2019). 눈덩이 샘플링. *SAGE 연구 방법 기초*. Reyes, A. (2011). 정치에서의 합법화 전략 담론: 말에서 행동으로. *담론과 사회*, 22(6), 781-807.
- Salajegheh, S., & Pirmoradi, N. (2013). 사회적 자본 조직. *사회 자본*, 7(12), 40-52. Saltz, JS, & Krasteva, I. (2022). 현재 접근 방식 빅데이터 과학 프로젝트 실행 - 체계적 문헌 검토. *PeerJ Computer Science*, 8, e862. Saltz, JS, & Lahiri, S. (2020). 기업의 필요성 빅데이터 과학 프로젝트를 위한 위험 관리 프레임워크. *DATA*(268-274쪽)
- 산토스, AS, Reis Neto, MT, & Verwaal, E. (2018). 문화적 자본이 개인의 직무 수행에 중요한가? 브라질에서 문화적, 사회적, 심리적 자본이 개인의 수행에 미치는 영향에 대한 대규모 조사. *생산성 및 성과 관리 국제 저널*, 67(8), 1352-1370.
- Varela, C., & Domingues, L. (2022). 데이터 과학의 위험 프로젝트-델파이 연구. *Procedia Computer Science*, 196, 982-989.
- Vigdor, Neil. (2019). Apple Card가 조사됨 

성별	차별	불만사항.
----	----	-------

<https://www.nytimes.com/2019/11/10/business/applecredit-card-investigation.html>
- Winchester, H., Boyd, AE, & Johnson, B. (2022년 5월). 소프트웨어 개발 및 사용에서의 교차성에 대한 탐구. *소프트웨어 엔지니어링에서의 성평등, 다양성 및 포용성에 대한 제3회 워크숍 회의록*(67-70쪽).
- Yeturu, K. (2020). 머신 러닝 알고리즘, 데이터 과학의 응용 및 관행. *통계 핸드북*(Vol. 43, pp. 81-206). Elsevier.